

AI Ethics and Regulation

BMED365: Topic List A01–A09

BMED365

Spring 2026

Overview

- 1 Bioethics and AI
- 2 EU AI Act
- 3 Responsibility and Fairness

A01: Discuss the four bioethical principles in an AI context

Beauchamp & Childress' Four Principles:

1. **Autonomi** (Respekt for selvbestemmelse)

- Informert samtykke til AI-bruk
- Rett til å vite om AI er involvert
- Mulighet til å choose bort AI-beslutninger

2. **Velgjørenhet** (Gjøre godt)

- AI shall forbedre patientutfall
- Validert og effektiv
- Tilgjengelig for alle

3. **Ikke-skade** (Primum non nocere)

- Unngå skade fra feil predictioner
- Minimere bias og diskriminering
- Sikkerhetstesting før clinical bruk

4. **Fairness** (Rettferdig advantageing)

- Lik tilgang til AI-forbedret helse
- Unngå systematisk diskriminering
- Representativ training data

Challenge

Prinsippene kan komme i konflikt – e.g. effektivitet (velgjørenhet) vs. privacy (autonomi)

A02: Identify types of bias in medical AI systems

Bias = systematisk skjevhet som fører til urettferdige utfall

Kilder til bias:

- ❶ **Hiscountsisk bias:** Trainingsdata reflekterer hiscountsisk unfairness
 - Example: Underrepresentasjon av minoriteter i clinique studier
- ❷ **Representasjonsbias:** Skjev patientpopulasjon i training data
 - Example: Modell trent på kun hvite patienter
- ❸ **Målbias:** Feil proxy-variabler
 - Example: Bruk av helsekostnader som goal på disease (korrelerer med rase)
- ❹ **Evaluationsbias:** Testdata er ikke representativ
- ❺ **Aggregeringsbias:** En modell for alle, ignorerer subgrupper

Consequence

Bias kan føre til at AI-systemer gir dårligere helsehjelp til allerede marginaliserte grupper.

A03: Explain privacy considerations when using LLMs

Privacyutfordringer med LLM:

Datalekkasje til tredjepart:

- Input sendes til LLM-leverandør
- Potensielt brukt til retraining
- Lagres på utenlandske servere

Memorisering:

- LLM kan ha “lært” persondata
- Kan generere sensitiv info i output

Identifikasjon:

- Re-identifisering fra tilsynelatende anonyme data
- Prompt kan avsløre kontekst

Tiltak:

- Aldri del patientidentifiserbar info med offentlige LLM
- Bruk lokale/sikre løsninger (chat.uib.no)
- Anonymisering og pseudonymisering

Important rule

Aldri legg inn patientdata i ChatGPT, Claude or andre offentlige LLM!

A04: Describe the main features of the EU AI Act

EU AI Act (vedtatt 2024):

- Verdens første omfattende AI-regulation
- Risikobasert tilnærming
- Gjelder alle som tilbyr or bruker AI i EU

Main principleer:

- 1 **Risikoclassification:** AI-systemer kategoriseres etter risiko
- 2 **Krav propotherwisejonale med risiko:** Høyere risiko = strengere krav
- 3 **Transparens:** Brukere må informeres om AI-bruk
- 4 **Menneskers tilsyn:** Human-in-the-loop for høyrisiko
- 5 **Dokumentasjon:** Teknisk dokumentasjon og logging
- 6 **CE-merking:** Samsvarsvurdering før lansering

Timeline

Gradvis innføring 2024–2027. Høyrisiko AI-krav gjelder fra 2026.

A05: Explain risk classification in the EU AI Act

Fire risikonivåer:

- ❶ **Uakseptabel risiko** (FORBUDT)
 - Social scoring, manipulasjon, real-time ansiktsgjenkjenning
- ❷ **Høy risiko** (STRENGE KRAV)
 - Medical utstyr og diagnostikk
 - Kritisk infrastruktur, utdanning, arbeidsmarked
 - Krever risikovurdering, dokumentasjon, menneskelig tilsyn
- ❸ **Begrenset risiko** (TRANSPARENSKRAV)
 - Chatbots, deepfakes
 - Må informere om at det er AI
- ❹ **Minimal risiko** (INGEN SPESIFIKKE KRAV)
 - Spamfiltre, spill-AI
 - Frivillige etiske retningslinjer

Medical AI

De fleste medicale AI-systemer vil classifys som **høy risiko**.

A06: Discuss requirements for high-risk AI in healthcare

Krav til høyrisiko AI-systemer:

Før lansering:

- Risikovurdering og -håndtering
- Høy datakvalitet og representativitet
- Teknisk dokumentasjon
- Transparens og brukerveiledning
- Cybersikkerhet
- Samsvarsvurdering (CE-merking)

Under bruk:

- Automatisk logging
- Menneskelig tilsyn
- Post-market overvåking
- Hendelsesrapportering
- Periodisk revurdering

Spesifikt for medical AI:

- Koordineres med [MDR](#) (Medical Devices Regulation)
- Clinical evidens og validation kreves
- Krav om explainability og robustness

A07: Reflect on responsibility allocation when AI fails

Hvem er responsible når AI tar feil?

Potensielle responsible:

- **AI-utvikleren:** Design, training, validation
- **Helseinstitusjonen:** Innkjøp, implementering, opplæring
- **Klinikeren:** Bruker AI, tar endelig beslutning
- **Pasienten:** Samtykker til AI-bruk?

Problemstillinger:

- AI som “black box” – vanskelig å understand feil
- Delt responsibility → utvannet responsibility?
- Automatiseringsbias – overtillit til AI

Rettslig utvikling:

- AI Liability Directive (EU)
- Produktresponsibility utvidet til AI
- Bevisbyrde kan legges på AI-leverandør

Main principle

Kliniker har fortsatt det endelige the responsibility – AI er et **verktøy**, ikke en erstatning.

A08: Know about GDPR-relevant aspects of AI

GDPR og AI i helse:

Nøkkelpinsipper:

- **Lovlig grunnlayers:** Samtykke, nødvendighet, berettiget interesse
- **Forgoalslimitation:** Data kun til oppgitt forgoal
- **Dataminimering:** Kun nødvendige data
- **Lagringslimitation:** Ikke layersre lenger enn nødvendig

Spesielle bestemmelser:

- **Art. 22:** Rett til å ikke bli utsatt for automatiserte beslutninger
- **Art. 9:** Helsedata er “spesiell kategori” – ekstra beskyttet
- **Art. 35:** **DPIA** (privacykonsekvensvurdering) for høyrisiko

Important

Pasientdata brukt til AI-training/bruk krever lovlig grunnlayers og ofte DPIA.

A09: Discuss algorithmic fairness

Fairness i ML: Ingen universell definisjon

Ulike fairnessdefinisjoner:

- 1 **Demografisk paritet:** Lik andel positive predictioner per gruppe
- 2 **Equalised odds:** Lik TPR og FPR per gruppe
- 3 **Calibration:** Konfidensscorer betyr det samme for alle grupper
- 4 **Individual fairness:** Like individer behandles likt

Problemet:

- Disse definisjonene er ofte **matematisk inkompatible**
- Valg av definisjon er en **valueladet** beslutning
- “Fair” i én fotherwisetand can be “unfair” i en annen

Medical example

Skal en risikomodell gi lik score til en 30-åring og 70-åring med samme symptoms? Alder er en risikofakcounts – er det diskriminering?

Summary: AI Ethics and Regulation

Bioethics og bias:

- A01: Fire bioetiske prinsipper in an AI context
- A02: Typer bias – hiscountsisk, representasjons-, goal-, evaluations-
- A03: Privacyhensyn ved LLM

EU AI Act:

- A04–A06: Risikobasert tilnærming, høyrisiko-krav for medisin

Responsibility and Fairness:

- A07: Responsibilityadvantageing – complex, kliniker har endelig responsibility
- A08: GDPR – spesialbeskyttelse for helsedata
- A09: Algoritmisk fairness – ingen simple løsning

Practical work in Lab 3

Diskuter etiske implikasjoner av LLM, bias-analyse, og privacyhensyn.