

# Evaluation of ML Models

## BMED365: Topic List E01–E10

BMED365

Spring 2026

## ❶ **Confusion Matrix** (confusion matrix)

- E01–E02: TP, TN, FP, FN

## ❷ **Fundamental metrikker**

- E03: Accuracy
- E04: Precision (precision)
- E05: Recall / Sensitivity
- E06: Specificity

## ❸ **Advanced metrikker**

- E07: F1-score
- E08: ROC-kurven og AUC
- E09: Ubalanserte dataset
- E10: TRIPOD-retningslinjer

# E01: Interpret a confusion matrix

What is it?

Tabell: predikerte vs. faktiske klasser

|         |     | Predikert |         |
|---------|-----|-----------|---------|
|         |     | Positiv   | Negativ |
| Faktisk | Pos | TP        | FN      |
|         | Neg | FP        | TN      |

Avlesning:

- **TP**: Korrekt positiv
- **TN**: Korrekt negativ
- **FP**: Falsk alarm
- **FN**: Oversett tilfelle

**Example:** Kreftscreening

- TP = Kreft oppdaget korrekt
- FN = Oversett kreft (*farlig!*)

## E02: TP, TN, FP, FN in a medical context

| Term | Definition                       | Medical example              |
|------|----------------------------------|------------------------------|
| TP   | Syk patient, modell sier syk     | Kreft korrekt identifisert   |
| TN   | Frisk patient, modell sier frisk | Frisk person bekreftet frisk |
| FP   | Frisk patient, modell sier syk   | Unødvendig biopsi            |
| FN   | Syk patient, modell sier frisk   | Oversett kreft               |

### Critical question i medisin

What is verst: **Falsk positiv** (FP) or **Falsk negativ** (FN)?

- Screening: FN er farligere (oversett disease)
- Invasiv treatment: FP can be farligere (unødvendig risiko)

## E03: Accuracy

### Definition

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} = \frac{\text{Korrekte predictioner}}{\text{Alle predictioner}}$$

### Example:

|    |     |
|----|-----|
| 85 | 10  |
| 5  | 900 |

$$\text{Accuracy} = \frac{85 + 900}{85 + 900 + 10 + 5} = \frac{985}{1000} = 98.5\%$$

### Warning

Høy accuracy can be misvisende ved ubalanserte dataset!

## E04: Precision (PPV)

### Definition

$$\text{Precision} = \frac{TP}{TP + FP} = \frac{\text{Sanne positive}}{\text{Alle predikerte positive}}$$

**Spørsmål:** “Av alle modellen sier er positive, hvor mange er faktisk positive?”

**Høy precision important når:**

- Kostbar oppfølging av positive
- Vil unngå falske alarmer
- Example: Sjelden disease

**Example:**

$$\text{Precision} = \frac{85}{85 + 5} = 94.4\%$$

*“94% av flyersgede pasienter er faktisk syke”*

## E05: Recall / Sensitivity

### Definition

$$\text{Recall} = \frac{TP}{TP + FN} = \frac{\text{Sanne positive}}{\text{Alle faktisk positive}}$$

**Spørsmål:** “Av alle som faktisk er positive, hvor mange fanger modellen opp?”

**Høy recall important når:**

- Alvorlig konsekvens av å overse (FN)
- Screening for farlig disease
- Example: Kreftscreening

**Example:**

$$\text{Recall} = \frac{85}{85 + 10} = 89.5\%$$

*“Vi fanger opp 89.5% av alle krefttilfor”*

### Andre navn

Recall = Sensitivity = True Positive Rate (TPR)

## E06: Specificity

### Definition

$$\text{Specificity} = \frac{TN}{TN + FP} = \frac{\text{Sanne negative}}{\text{Alle faktisk negative}}$$

**Spørsmål:** “Av alle som faktisk er negative, hvor mange identifiserer modellen korrekt?”

### Høy specificity important når:

- Vil unngå unødvendige inngrep
- Kostbar/risikabel treatment
- Example: Bekreftelsetester

### Example:

$$\text{Specificity} = \frac{900}{900 + 5} = 99.4\%$$

*“99.4% av friske korrekt identifisert som friske”*

### Trade-off

Høy sensitivity ↔ Lav specificity (og omvendt). Justering av threshold value påvirker begge.



### Definition

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

*Harmonisk gjennomsnitt av precision og recall*

### Why harmonisk gjennomsnitt?

- Straffer ekstreme valueer hardere enn aritmetisk gjennomsnitt
- Precision = 100%, Recall = 0% → F1 = 0% (ikke 50%!)

### Når bruke F1?

- Ubalanserte dataset
- Når både FP og FN er importante
- Compare models

### Example:

$$F1 = 2 \cdot \frac{0.944 \cdot 0.895}{0.944 + 0.895} = 0.92$$


## E08: ROC-kurven og AUC

### ROC-kurve:

- Receiver Operating Characteristic
- Plotter TPR vs. FPR for ulike terskler
- Viser trade-off mellom sensitivity og specificity

### AUC (Area Under Curve):

- Arealet under ROC-kurven
- Verdi mellom 0 og 1
- $AUC = 0.5$ : tilfeldig gjetting
- $AUC = 1.0$ : perfekt klassifikasjonsresultat



### Rule of thumb

$AUC > 0.9$ : Utmerket     $AUC 0.8-0.9$ : God     $AUC 0.7-0.8$ : OK     $AUC < 0.7$ : Svak

## E09: When accuracy is insufficient

### Problemet med ubalanserte dataset:

**Example:** 1000 pasienter

- 950 friske, 50 syke
- Modell predikerer ALLE som friske

### Resultater:

$$\text{Accuracy} = \frac{950}{1000} = 95\%$$

$$\text{Recall} = \frac{0}{50} = 0\%$$

**Høy accuracy, men ubrukelig modell!**

### Solutioner:

- Bruk F1-score or AUC
- Fokuser på recall for screening
- Rapporter alle metrikker
- Sammenlign med baseline

### Teknikker for ubalanse:

- Oversampling (SMOTE)
- Undersampling
- Class weights
- Stratifisert splitting

## E10: TRIPOD-retningslinjer

### What is TRIPOD?

Transparent **R**eporting of a multivariable prediction model for Individual **P**rognosis **O**r **D**iagnosis

### Main points for rapportering av ML i medisin:

- 1 Tydelig description av studiepopulasjon
- 2 Definer utfall og predikcountser klart
- 3 Beskriv missing data håndtering
- 4 Rapporter modellutvikling detaljert
- 5 Intern validation (cross-validation)
- 6 Ekstern validation hvis mulig
- 7 Rapporter kalibrering og diskriminering
- 8 Diskuter limitasjoner

### Why important?

TRIPOD sikrer **reproduserbarhet** og **kvalitetskontroll** av predictionsmodels i helsefotherwisekning.

# Summary: E01–E10

## Confusion Matrix

|    |    |
|----|----|
| TP | FN |
| FP | TN |

## Metrikker:

$$\text{Recall} = \frac{TP}{TP+FN}$$

$$\text{Precision} = \frac{TP}{TP+FP}$$

$$\text{Specificity} = \frac{TN}{TN+FP}$$

## Avansert:

### F1-score:

Kombinerer Precision + Recall

### ROC/AUC:

Helhetsbilde uavhengig av terskel

## Key points

- Velg metrikk basert på medical kontekst (FN vs. FP konsekvenser)
- Accuracy er ofte utilstrekkelig – bruk F1, AUC, precision, recall
- ROC/AUC gir helhetsbilde uavhengig av threshold value
- Følg [TRIPOD](#) for transparent rapportering