

Evaluation of ML Models

BMED365: Topic List E01–E10

BMED365

Spring 2026

❶ **Confusion Matrix** (confusion matrix)

- E01–E02: TP, TN, FP, FN

❷ **Fundamental metrikker**

- E03: Accuracy (accuracy)
- E04: Precision (precision)
- E05: Recall / Sensitivity (sensitivity)
- E06: Specificity (specificity)

❸ **Advanced metrikker**

- E07: F1-score
- E08: ROC-kurven og AUC
- E09: Ubalanserte dataset
- E10: TRIPOD-retningslinjer

E01: Interpret en Confusion Matrix (confusion matrix)

What is it?

Tabell: predikerte vs. faktiske klasser

		Predikert	
		Positiv	Negativ
Faktisk	Pos	TP	FN
	Neg	FP	TN

Avlesning:

- **TP**: Korrekt positiv
- **TN**: Korrekt negativ
- **FP**: Falsk alarm
- **FN**: Oversett tilfelle

Example: Kreftscreening

- TP = Kreft oppdaget korrekt
- FN = Oversett kreft (*farlig!*)

E02: TP, TN, FP, FN i medisinsk kontekst

Term	Definition	Medical example
TP	Syk pasient, modell sier syk	Kreft korrekt identifisert
TN	Frisk pasient, modell sier frisk	Frisk person bekreftet frisk
FP	Frisk pasient, modell sier syk	Unødvendig biopsi
FN	Syk pasient, modell sier frisk	Øversett kreft

Critical question i medisin

What is verst: **Falsk positiv** (FP) or **Falsk negativ** (FN)?

- Screening: FN er farligere (oversett sykdom)
- Invasiv behandling: FP kan være farligere (unødvendig risiko)

E03: Accuracy (accuracy)

Definition

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} = \frac{\text{Korrekte prediksjoner}}{\text{Alle prediksjoner}}$$

Example:

85	10
5	900

$$\text{Accuracy} = \frac{85 + 900}{85 + 900 + 10 + 5} = \frac{985}{1000} = 98.5\%$$

Warning

Høy accuracy kan være misvisende ved ubalanserte dataset!

E04: Precision (precision / PPV)

Definition

$$\text{Precision} = \frac{TP}{TP + FP} = \frac{\text{Sanne positive}}{\text{Alle predikerte positive}}$$

Spørsmål: “Av alle modellen sier er positive, hvor mange er faktisk positive?”

Høy precision viktig når:

- Kostbar oppfølging av positive
- Vil unngå falske alarmer
- Example: Sjelden sykdom

Example:

$$\text{Precision} = \frac{85}{85 + 5} = 94.4\%$$

“94% av flaggede pasienter er faktisk syke”

E05: Recall / Sensitivity (sensitivity)

Definition

$$\text{Recall} = \frac{TP}{TP + FN} = \frac{\text{Sanne positive}}{\text{Alle faktisk positive}}$$

Spørsmål: “Av alle som faktisk er positive, hvor mange fanger modellen opp?”

Høy recall viktig når:

- Alvorlig konsekvens av å overse (FN)
- Screening for farlig sykdom
- Example: Kreftscreening

Example:

$$\text{Recall} = \frac{85}{85 + 10} = 89.5\%$$

“Vi fanger opp 89.5% av alle krefttilfor”

Andre navn

Recall = Sensitivity = True Positive Rate (TPR)

E06: Specificity (specificity)

Definition

$$\text{Specificity} = \frac{TN}{TN + FP} = \frac{\text{Sanne negative}}{\text{Alle faktisk negative}}$$

Spørsmål: “Av alle som faktisk er negative, hvor mange identifiserer modellen korrekt?”

Høy specificity viktig når:

- Vil unngå unødvendige inngrep
- Kostbar/risikabel behandling
- Example: Bekreftelsetester

Example:

$$\text{Specificity} = \frac{900}{900 + 5} = 99.4\%$$

“99.4% av friske korrekt identifisert som friske”

Trade-off

Høy sensitivity ↔ Lav specificity (og omvendt). Justering av terskelverdi påvirker begge.

Definition

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

Harmonisk gjennomsnitt av precision og recall

Why harmonisk gjennomsnitt?

- Straffer ekstreme verdier hardere enn aritmetisk gjennomsnitt
- Precision = 100%, Recall = 0% → F1 = 0% (ikke 50%!)

Når bruke F1?

- Ubalanserte dataset
- Når både FP og FN er viktige
- Compare modor

Example:

$$F1 = 2 \cdot \frac{0.944 \cdot 0.895}{0.944 + 0.895} = 0.92$$


E08: ROC-kurven og AUC

ROC-kurve:

- Receiver Operating Characteristic
- Plotter TPR vs. FPR for ulike terskler
- Viser trade-off mellom sensitivity og specificity

AUC (Area Under Curve):

- Arealet under ROC-kurven
- Verdi mellom 0 og 1
- $AUC = 0.5$: tilfeldig gjetting
- $AUC = 1.0$: perfekt klassifikator



Tommelfingerregel

$AUC > 0.9$: Utmerket $AUC 0.8-0.9$: God $AUC 0.7-0.8$: OK $AUC < 0.7$: Svak

E09: Når accuracy er utilstrekkelig

Problemet med ubalanserte dataset:

Example: 1000 pasienter

- 950 friske, 50 syke
- Modell predikerer ALLE som friske

Resultater:

$$\text{Accuracy} = \frac{950}{1000} = 95\%$$

$$\text{Recall} = \frac{0}{50} = 0\%$$

Høy accuracy, men ubrukelig modell!

Løsninger:

- Bruk F1-score or AUC
- Fokuser på recall for screening
- Rapporter alle metrikker
- Sammenlign med baseline

Teknikker for ubalanse:

- Oversampling (SMOTE)
- Undersampling
- Class weights
- Stratifisert splitting

E10: TRIPOD-retningslinjer

What is TRIPOD?

Transparent **R**eporting of a multivariable prediction model for Individual **P**rognosis **O**r **D**iagnosis

Hovedpunkter for rapportering av ML i medisin:

- 1 Tydelig beskrivelse av studiepopulasjon
- 2 Definer utfall og prediktorer klart
- 3 Beskriv missing data håndtering
- 4 Rapporter modellutvikling detaljert
- 5 Intern validation (cross-validation)
- 6 Ekstern validation hvis mulig
- 7 Rapporter kalibrering og diskriminering
- 8 Diskuter begrensninger

Why viktig?

TRIPOD sikrer **reproduserbarhet** og **kvalitetskontroll** av prediksjonsmodor i helseforskning.

Summary: E01–E10

Confusion Matrix

TP	FN
FP	TN

Metrikker:

$$\text{Recall} = \frac{TP}{TP+FN}$$

$$\text{Precision} = \frac{TP}{TP+FP}$$

$$\text{Specificity} = \frac{TN}{TN+FP}$$

Avansert:

F1-score:

Kombinerer Precision + Recall

ROC/AUC:

Helhetsbilde uavhengig av terskel

Key points

- Velg metrikk basert på medisinsk kontekst (FN vs. FP konsekvenser)
- Accuracy er ofte utilstrekkelig – bruk F1, AUC, precision, recall
- ROC/AUC gir helhetsbilde uavhengig av terskelverdi
- Følg **TRIPOD** for transparent rapportering