

Machine Learning – Fundamental Concepts

BMED365: Topic List M01–M10

BMED365

Spring 2026

1 What is machine learning?

- M01: Definition og distinguish from tradisjonell programmering
- M02: Supervised vs. Unsupervised learning
- M03: Features og Labels

2 Validation and Model Types

- M04–M05: Trainings-/test set, overfitting/underfitting
- M06–M07: Bias-Variance trade-off, K-fold cross-validation
- M08–M10: Baseline, classification vs. regression, enkle models

M01: Define machine learning og distinguish from tradisjonell programmering

Tradisjonell programmering:

- Eksplisitte regler definert av programmerer
- if-else logikk, deterministisk
- Input + Regler $\rightarrow$ Output
- Krever full domenekunnskap på forhånd

Machine Learning:

- Lærer regler fra data automatic
- Mønster-gjenkjenning, statistisk
- Input + Output $\rightarrow$ Regler (modell)
- Skalerer med datamengde

Definition (Tom Mitchell, 1997)

*"A computer program is said to **learn from experience** E with respect to some task T and some performance measure P , if its performance on T , as measured by P , improves with experience E ."*

Definition (Tom Mitchell, 1997) – in Norwegian

*"Et dataprogram sies å **lære av erfaring** E med hensyn til en task T og et ytelsesgoal P , dersom dets ytelse på T , goalt ved P , forbedres med erfaring E ."*

M02: Supervised vs. Unsupervised læring

✔ Supervised (veiledet) læring:

- Data har **labels** (fasit/merkelapper)
- Modellen lærer input→output-mapping
- Typer: Classification, regression
- Medical: Diagnostisering, prognos
- Krever manual annotering av data

🔍 Unsupervised (ikke-veiledet) læring:

- Data **uten** labels
- Finner skjulte mønstre/strukturer
- Typer: Klynging, dimensjonsreduksjon
- Medical: Pasient-subgrupper
- Ingen fasit – utfotherwisekende analyse

Semi-supervised (delvis veiledet) – prinsipper og applylser

Kombinerer få merkede eksempler med mange umerkede. Nyttig når annotering er dyrt/tidkrevende.

Prinsipper: *Smoothness* – nærliggende datapunkter har ofte samme label. *Tabulært*: pasienter med like lab-valueer har ofte samme diagnosis. *Image*: MR-snitt med lignende pikselintensiteter viser lignende patologi. *Cluster* – data grupperer seg naturlig; punkter i samme klynge tilhører ofte samme klasse. *Tabulært*: pasienter med diabetes klynger seg i feature-rommet. *Image*: hjerne-MR av friske vs. Alzheimer danner separate klynger. *Manifold* – et 256×256 bilde = 65536 piksler, men meningsfull variasjon bestemmes av få fakcountser (anatomi, patologi). Image "fyller" ikke hele rommet, men ligger på en lavdim. flate.

Applications: Medical bildesegmentation, tekstclassification, talegjenkjenning, drugoppdagelse, genomikk.

M03: Features (input) og Labels (output)

Definitions

- **Features** (X): Inputvariabler / egenskaper / kjennetegn som describer dataene
- **Labels** (y): Målvariabel / det vi ønsker å predikere (fasit)

Example – Hjertediseasesprediction (tabulære data):

Alder	Kolesterol	Blodtrykk	BMI	Sykdom?
55	240	140	28	Ja
32	180	120	23	Nei
67	210	155	31	Ja

Features X (kolonner = variabler)

Label y

Rader = observasjoner/patienter, Kolonner = variabler → **Matrise**

M04: Why training set og test set?

Problem: How do we know om modellen generaliserer til nye data?

The solution: Data-splitting

- 1 Del datasetet i to (or tre) deler
- 2 **Training set** ($\sim 70-80\%$): Tren modellen
- 3 **Test set** ($\sim 20-30\%$): Evaluer på usett data
- 4 (Validation set: Tuning av hyperparametre)

Training (70%)

Test

Important

Modellen shall **aldri** se testdataene under training!


scikit-learn

```
train_test_split(X, y, test_size=0.2)
```

M05: Overfitting (Overfitting) og Underfitting (Underfitting)


Underfitting:

- For simple modell
- Høy bias
- Dårlig på training og test




God adaptation:

- Riktig complexitet
- Balanse
- Generaliserer godt



Overfitting:

- For complex modell
- Høy varians
- Lærer støy i dataene



Kjennetegn på overfitting

Scouts fotherwisekjell mellom trainings- og test-**ytelse** (performance). **Ytelse** = goal på hvor godt modellen presterer (e.g. accuracy, F1).

M06: Bias-Variance Trade-off

Totalt predictionsfeil:


$$\text{MSE} = \underbrace{\text{Bias}^2}_{\text{systematisk feil}} + \underbrace{\text{Varians}}_{\text{tilfeldig feil}} + \underbrace{\sigma^2}_{\text{irreducible}}$$

Bias (systematisk feil):

- Feil pga. forenklet modell
- Høy bias → **underfitting**
- Modellen “misser” mønsteret

Varians (tilfeldig feil):

- Sensitiv for små endringer i data
- Høy varians → **overfitting**
- Modellen “husker” støy



The goal


Finn balansen som minimerer **total feil** på nye data. σ^2 = støy i data (kan ikke reduseres).

M07: K-fold cross-validation

Problem: Ett enkelt train/test-split kan gi tilfeldige resultater

Solution: K-fold Cross-Validation

- 1 Del data i k like skuntse deler ("folds")
- 2 For hver fold: bruk den som test, resten som training
- 3 Average av alle k evaluationer



Advantages: Mer robust estimat, bruker all data for både training og testing

M08: Baseline model

What is a baseline?

En **simple referansemodell** som vår ML-modell må slå to være nyttig.

Examples på baselines:

- **Classification:** Prediker alltid majoritetsklassen
 - Dataset med 90% friske, 10% syke $\rightarrow$ baseline accuracy = 90%
- **Regression:** Prediker alltid gjennomsnittsverdien
- **Tidsserie:** Bruk forrige value som prediction

Why important?

90% accuracy høres imponerende ut, men ikke hvis baseline er 90%! Viser om ML tilfører **faktisk value**. Avslører ubalanserte dataset.

■ Classification:

- Predikerer **kategorier/klasser**
- Diskrete utfall
- Examples:
 - Syk / Frisk
 - Kreft type A / B / C

Evaluationsmetriker:

- Accuracy, Precision, Recall
- F1-score, AUC-ROC

📈 Regression:

- Predikerer **kontinuerlige valueer**
- Numeriske utfall
- Examples:
 - Blodtrykk
 - Medikamentdosering


Evaluationsmetriker:

- MSE, RMSE, MAE
- R^2 (forklart varians)

M10: Simple ML models

Beslutningstre:

- Serier av ja/nei-spørsmål
- Lett å interpret
- Kan overtilpasse




k-Nearest Neighbourhood:

- Finn k mest like eksempler
- Majoritetsvotering
- Enkel, men treg



Logistisk regression:

- Lineær grense
- Gir sannsynligheter
- Rask og tolkbar



Tip

Start alltid med enkle models før du prøver complexe!

Summary: M01–M10

Key concepts:

- ML lærer fra data
- Supervised / Unsupervised / Semi-supervised
- Features (X), Labels (y)
- Training / test / validation
- Over-/underfitting

Beste praksis:

- Cross-validation
- Sammenlign med baseline
- Classification $\neq$ Regression
- Start simplit
- Bias-varians-balanse

Fremtid: ML + GenAI

- LLM-agenter for dataanalyse
- Multimodale models (tekst+bilde)
- RAG + clinique retningslinjer
- Automatisert ML-pipeline
- Human-in-the-loop AI

Medical relevance – ML-applylser i helse, medisin og bioteknologi

Diagnostikk: Imagediagnostikk (radiologi, patologi, oftalmologi, dermatologi), biomarkerdeteksjon, EKG/EEG-analyse.

Prognose: Overlevelse (OS), progresjonsfri overlevelse (PFS), reinnleggelse, mortalitetsrisiko, diseasesprogresjon.

Terapi: Terapivalg, doseoptimalisering, treatmentsrespons, stråleplanlegging, kirurgisk navigasjon.

Legemiddel: Drugability, goalidentifikasjon, ADMET-prediction, virtual screening, de novo molekyldesign.

Helsesystem: Ressursallokering, kapasitetsplanlegging, triagering, ventelisteoptimering, utbruddsdeteksjon.

Genomikk/biotek: Variantclassification, genekspressjon, proteinstruktur (AlphaFold), single-cell, CRISPR off-target.

Psykatri/nevrologi: Stemningsanalyse, talemærker, nevrodegenerasjon, anfallsprediction.

Folkehelse: Epidemiologisk modeling, vaksinestrategi, sosiale determinanter, helseøkonomi (QALY/DALY).

Human-in-the-loop: Pasientbilde → **ML: "mulig malign" (87%)** → Radiolog evaluater → Bekrefter/avviser → Feedback → Modell forbedres