

Trustworthy AI og Robustness

BMED365: Topic List T01–T07

BMED365

Spring 2026

1 Trustworthy AI

- T01: Define trustworthy AI iht. EU-retningslinjer

2 Robustness og usikkerhet

- T02: Explain konseptet robustness i ML/AI
- T03: Describe datadrift og dens konsekvenser
- T04: Explain epistemisk vs. aleatorisk usikkerhet

3 Menneske-maskin samspill

- T05: Describe human-in-the-loop (HITL) systemer
- T06: Discuss viktigheten av kontinuerlig monitorering

4 Sikkerhetstrusler

- T07: Know about adversarial attacks

T01: Define trustworthy AI iht. EU-retningslinjer

EU High-Level Expert Group on AI (2019):

Definition

Trustworthy AI er AI som er lovlig, etisk og robust – både teknisk og sosialt.

Syv nøkkelkrav:

- 1 **Menneskers handlingsrom og tilsyn** – Human agency & oversight
- 2 **Teknisk robustness og sikkerhet** – Technical robustness & safety
- 3 **Privacy og dataforvaltning** – Privacy & data governance
- 4 **Transparens** – Transparency
- 5 **Mangfold, ikke-diskriminering, fairness** – Diversity, non-discrimination, fairness
- 6 **Sosial og miljømessig velferd** – Societal & environmental well-being
- 7 **Responsibilitylighet** – Accountability

Medical relevans

Høyrisiko AI-systemer i helse må oppfylle disse kravene under [EU AI Act](#).

T02: Explain konseptet robustness i ML/AI

Robustness = modellens evne til å prestere pålitelig under variasjon

En robust modell:

- Gir **konsistente resultater** på lignende input
- **Degraderer gradvis** (ikke katastrofalt) ved støy
- Generaliserer godt til nye, usette data

Typer robustness:

- **Støyrobustness:** Toleranse for tilfeldig støy
- **Distribusjonell robustness:** Endringer i datafordeling
- **Adversarial robustness:** Motstand mot bevisste angrep
- **Temporal robustness:** Stabilitet over tid

In medicine

En robust medisinsk AI gir pålitelige prediksjoner uavhengig av variasjon i bildekvalitet, pasientpopulasjon, or utstyr.

T03: Describe datadrift og dens konsekvenser

Datadrift (distributional shift):

- Forskjell mellom **trainingsdata** og **produksjonsdata**
- Modellen møter data som ikke ligner det den er trent på

Typar drift:

- 1 **Covariate shift**: Input-fordeling endres (f.eks. ny pasientdemografi)
- 2 **Label shift**: Forekomst av klasser endres (f.eks. pandemier)
- 3 **Concept drift**: Sammenhengen mellom input og output endres

Examples i medisin:

- Modell trent på data fra USA brukes i Norge
- Ny MR-skanner gir andre bildekarakteristikker
- COVID endret innleggelsesmønstre

Konsekvens

Modellen kan **feile stille** – gir prediksjoner med høy konfidens som er feil!

T04: Explain forskjellen mellom epistemisk og aleatorisk usikkerhet

Epistemisk usikkerhet:

- Usikkerhet pga. **manglende kunnskap**
- “Vi vet ikke nok ennå”
- **Kan reduseres** med mer data
- Modellen er usikker på områder med lite trainingsdata

Example:

- Sjelden sykdom med få trainingseksempler
- Usikkerhet fordi modellen mangler erfaring

Aleatorisk usikkerhet:

- **Iboende** tilfeldig variasjon i data
- “Verden er usikker”
- **Kan ikke reduseres** med mer data
- Støy i målinger, naturlig variasjon

Example:

- To pasienter med identiske features har ulike utfall
- Usikkerhet fordi utfall er genuint usikkert

Praktisk betydning

Epistemisk usikkerhet signaliserer når modellen bør “si ifra” at den er usikker, og mennesker bør overta.

T05: Describe human-in-the-loop (HITL) systemer

Human-in-the-loop (HITL):

- Mennesker er **integrert** i AI-systemets beslutningsprosess
- AI gir anbefalinger, mennesker tar endelige beslutninger

Tre hovedvarianter:

- 1 **Human-in-the-loop**: Menneske involveres i hver beslutning
- 2 **Human-on-the-loop**: Menneske overvåker og kan overstyre
- 3 **Human-out-of-the-loop**: Full autonomi (ikke anbefalt i medisin)

Advantages med HITL i medisin:

- Kombinerer AI-effektivitet med menneskelig ekspertise
- Fanger opp AI-feil før de får konsekvenser
- Opprettholder klinisk responsibility, bygger tillit gradvis

EU AI Act

Høyrisiko AI-systemer **krever** effektiv menneskelig tilsyn.

T06: Discuss viktigheten av kontinuerlig monitorering

Why **kontinuerlig monitorering**?

- ML-modor **degraderer over tid** (model drift)
- Verden endrer seg, data endrer seg
- Feil i produksjon kan ha alvorlige konsekvenser

Hva bør overvåkes?

Ytelsesmetrikker:

- Accuracy, precision, recall over tid
- Kalibrering av konfidensscorer
- Sammenligning med baseline

Datakarakteristikker:

- Input-fordeling (drift-deteksjon)
- Andel out-of-distribution input
- Feature-statistikk

Tiltak ved problemer:

- **Re-training** med ferske data – oppdater modellen på nyere, representative data
- **Varsling og eshalling** – automatisk varsling ved ytelsesfall or drift
- **Fallback** – bytt til enklere modell or menneskelig vurdering ved usikkerhet

T07: Know about adversarial attacks

Adversarial attacks = bevisst manipulering av AI-input

- Små, tilsynelatende usynlige endringer som lurer modellen
- Kan få en korrekt klassifikasjon til å bli **fullstendig feil**

Examples:

Bilder:

- Piskel-perturbasjoner usynlige for mennesker
- "Panda" → "Gibbon" med 99% konfidens
- Klistremerker som lurer selvkjørende biler

Tekst (LLM):

- Prompt injection
- Jailbreaking
- Omgå sikkerhetsfiltre

Medical risiko og forsvar

Risiko: En angriper kunne manipulere et røntgenbilde slik at AI overser patologi, or skaper falske funn.

Forsvar: Adversarial training, input-validation, ensemble-metoder, robustnessstesting.

Summary: Trustworthy AI og Robustness

Key points:

- **T01:** EU's 7 krav til trustworthy AI
- **T02:** Robustness – konsistente resultater under variasjon
- **T03:** Distributional shift – når data i praksis avviker fra training
- **T04:** Epistemisk (kan reduseres) vs. aleatorisk (iboende) usikkerhet
- **T05:** HITL – mennesker i beslutningssløyfen
- **T06:** Kontinuerlig monitorering – fange drift og degradering
- **T07:** Adversarial attacks – bevisst manipulering

Hovedbudskap

Trustworthy AI i medisin krever robuste modor, menneskelig tilsyn, kontinuerlig monitorering og bevissthet om sikkerhetsrisikoer. Teknikk alene er ikke nok – det kreves også organisatoriske og regulatoriske tiltak.