

Explainable AI (XAI)

BMED365: Topic List X01–X08

BMED365

Spring 2026

1 Why explainability?

- X01: Explain why explainability is important in medical AI

2 Types of Explainability

- X02: Distinguish between global and local explainability
- X03: Distinguish between ante-hoc and post-hoc explainability

3 XAI-metoder

- X04: Describe SHAP (SHapley Additive exPlanations)
- X05: Describe LIME (Local Interpretable Model-agnostic Explanations)
- X06: Explain Grad-CAM for CNN visualization

4 Limitations and Challenges

- X07: Discuss limitations of XAI methods
- X08: Know about attention visualization in LLMs

X01: Explain why explainability is important in medical AI

Challengeen med “**black box**” AI:

- Komplekse models (dype nettverk, LLM) gir predictioner without explain *hvorfor*
- In medicine er dette problematisk av flere grunner

Why explainability er critical i medisn:

- 1 **Tillit:** Leger og pasienter må stole på anbefalingene
- 2 **Responsibility:** Ved feil – hvem har the responsibility?
- 3 **Regulation:** EU AI Act krever explainability for høyrisiko-AI
- 4 **Læring:** Understand hva modellen har lært (og feil-lært)
- 5 **Feilsøking:** Identifisere bias og svakheter
- 6 **Clinical integration:** AI som beslutningsstøtte, ikke autonom

Medical practice

En lege som ikke kan explain why de anbefaler en treatment vil miste pasientens tillit. Det samme gjelder AI.

X02: Distinguish between global and local explainability

Global explainability:

- Explains modellens **generelle behavior**
- “Hvilke features er importantst totalt sett?”
- “How påvirker alder predictionen generelt?”

Metoder:

- Feature importance
- Partial dependence plots
- Globale SHAP-valueer

Lokal explainability:

- Explains én **spesifikk prediction**
- “Why fikk *denne* patienten høy risikoscore?”
- “Hvilke piksler påvirket classificationen?”

Metoder:

- LIME
- SHAP (individuelle valueer)
- Grad-CAM (for bilder)

Begge er importante

Global: Understand modellen som helhet, validere mot domenkunnskap

Lokal: Explain beslutninger til patienter og kollegaer

X03: Distinguish between ante-hoc and post-hoc explainability

Ante-hoc (innebygd):

- Explainability **bygget inn** i modellen
- Modellen er designet to være tolkbar
- “Interpretable by design”

Examples:

- Lineær regression (koeffisienter)
- Beslutningstrær (regler)
- Attention-vektor (delvis)

Fordel: Ekte forklaring

Ulempe: Ofte mindre nøyaktig

Post-hoc (etterpå):

- Forklaringsmetode **layerst til** etter training
- Modellen er fortsatt en “black box”
- Separate verktøy for interpretation

Examples:

- SHAP, LIME
- Grad-CAM
- [Saliency maps](#)

Fordel: Kan brukes på complexe models

Ulempe: Approksimerer, can be misvisende

Trade-off

Ofte et valg mellom tolkbarhet (ante-hoc) og ytelse (complex modell + post-hoc)

X04: Describe SHAP (SHapley Additive exPlanations)

SHAP: Basert på spillteori

- Shapley-valueer: Fair advantageing av “gevinst” mellom spillere
- Her: Hvor mye bidrar hver feature til predictionen?

How SHAP works:

- 1 For hver feature: Beregn gjennomsnittlig bidrag til prediction
- 2 Tar hensyn til alle mulige kombinasjoner av features
- 3 Gir en value per feature for hver prediction

Styrker:

- Teoretisk solid ([Shapley-aksiomer](#))
- Konsistent og lokalt nøyaktig
- Fungerer for alle modelltyper

Visualiseringer:

- **Waterfall plot:** Én prediction
- **Summary plot:** Global oversikt
- **Force plot:** Interaktiv

Python

```
import shap; explainer = shap.Explainer(model); shap_values = explainer(X)
```

X05: Describe LIME (Local Interpretable Model-agnostic Explanations)

LIME: Lokal tilnærming med simple modell

Main idea:

- 1 Velg én prediction å explain
- 2 Generer **perturberte** (fotherwisetyrrede) versjoner av input
- 3 Kjør den complexe modellen på alle versjoner
- 4 Tren en **simple, tolkbar modell** (e.g. lineær) lokalt
- 5 Bruk den enkle modellen til å explain

Styrker:

- Modell-agnostisk
- Intuitivt understandelig
- Fungerer for tekst, bilder, tables

Svakheter:

- Ustabil – ulike kjøringar kan gi ulike svar
- Valg av nabolayers er vilkårlig
- Kan være misvisende

Example: Tekstclassification

LIME viser which ord som bidro mest til classificationen "spam" vs. "ikke spam"

X06: Explain Grad-CAM for CNN visualization

Grad-CAM: Gradient-weighted Class Activation Mapping

- Spesialisert for **konvolusjonelle nettverk (CNN)**
- Viser **which bildområder** som påvirket classificationen

How it works:

- 1 Beregn gradienter av output with respect to feature maps i siste konvolusjonslayers
- 2 Vekt feature maps med gjennomsnittlig gradient
- 3 Kombiner til et **heatmap** som overlays på originalbildet

Medical application:

- Røntgen/CT: “Modellen fokuserte på dette området for lungefunn”
- Dermatologi: “Disse pikslene påvirket melanom-diagnosin”
- Validation: Sjekk at modellen ser på riktig område!

Important innsikt

Grad-CAM kan avsløre om modellen bruker **spuriøse korrelasjoner** (e.g. ser på tekst i bildet, ikke patologi)

X07: Discuss limitations of XAI methods

XAI er ikke perfekt – **importante limitationer**:

1 Forklaringer er approksimeringer

- Post-hoc metoder explains ikke den *ekte* modellen
- Kan være misvisende or inkonsistente

2 Ustabilitet

- LIME kan gi ulike forklaringer for samme input
- Små endringer i input kan gi scoutse endringer i forklaring

3 Forinterpretationsbyrde

- Hvem shall interpret forklaringene? Krever ekspertise
- Risiko for overtillit til forklaringer

4 Beregningsmessig kost

- SHAP can be svært treg for scoutse models

Husk

XAI er et verktøy for innsikt, ikke en garanti for at modellen er “riktig” or rettferdig.

X08: Know about attention visualization in LLMs

Attention-visualisering i LLM: Innebygd “forklaring”?

- Transformer-modells bruker **self-attention**
- Attention-vektar viser which tokens modellen “ser på”
- Kan visualiseres som heatmaps

Example:

*“Pasienten har **diabetes** og tar **metformin**”*

Attention-visualisering kan vise at “metformin” har høy attention på “diabetes”

Muligheter:

- Innsikt i modellens fokus
- Ante-hoc (innebygd i modellen)
- Lett tilgjengelig

Limitations:

- Attention $\neq$ forklaring
- Mange layers, mange “heads”
- Kan være vanskelig å interpret
- Viser korrelasjon, ikke kausalitet

Fotherwiseiktighet

Attention-visualiseringer bør brukes som supplement, ikke som endelig forklaring.

Summary: Explainable AI (XAI)

Key points:

- **X01:** Explainability er critical i medisin (tillit, responsibility, regulation)
- **X02:** Global vs. lokal explainability
- **X03:** Ante-hoc (innebygd) vs. post-hoc (etterpå)
- **X04:** SHAP – spillteoretisk, konsistent
- **X05:** LIME – lokal tilnærming, modell-agnostisk
- **X06:** Grad-CAM – visualiser CNN-fokus i bilder
- **X07:** Limitations – approksimeringer, ustabilitet
- **X08:** Attention-visualisering i LLM

Practical work in Lab 2 og Lab 3

- Lab 2: Bruk Grad-CAM to interpret CNN-classification
- Lab 3: Diskuter explainability og transparens i LLM